AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM – AIO COURSE 2026

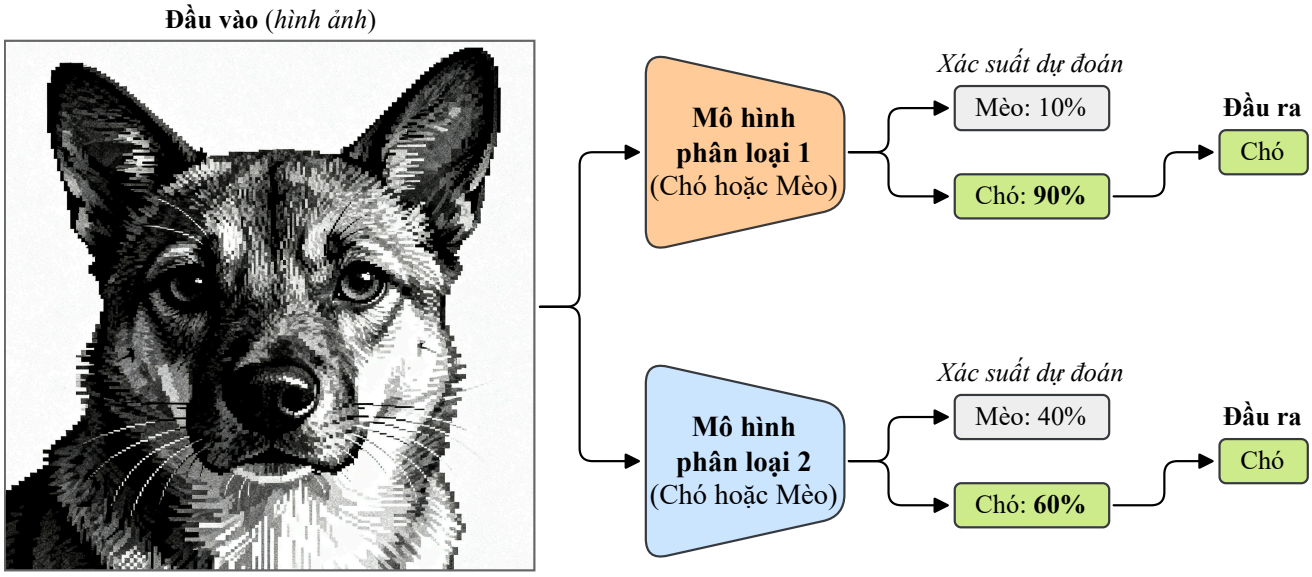
Introduction: Cross-Entropy

Nguyễn Anh Khôi Dương Đình Thắng Đinh Quang Vinh

Giới thiệu

Khi xây dựng một mô hình học máy để phân loại, câu hỏi đầu tiên không phải là "mô hình có đúng không?" mà là "mô hình tự tin đến mức nào về câu trả lời của nó?" Chính sự khác biệt này làm nên bản chất của học máy hiện đại.

Hãy tưởng tượng hai mô hình đều nhận diện đúng một bức ảnh là con mèo. Mô hình thứ nhất nói "Tôi chắc chắn 90% đây là mèo", trong khi mô hình thứ hai chỉ tự tin với 60%. Cả hai đều đúng về mặt kết quả cuối cùng, nhưng liệu rằng chúng có tốt như nhau không? Do đó, chúng ta cần một con số cụ thể để trả lời câu hỏi này, nghĩa là, con số đó phải phản ánh được mô hình thứ nhất tốt hơn bao nhiêu so với mô hình thứ hai.



Hình 1: Minh họa hai mô hình dự đoán với độ tự tin khác nhau.

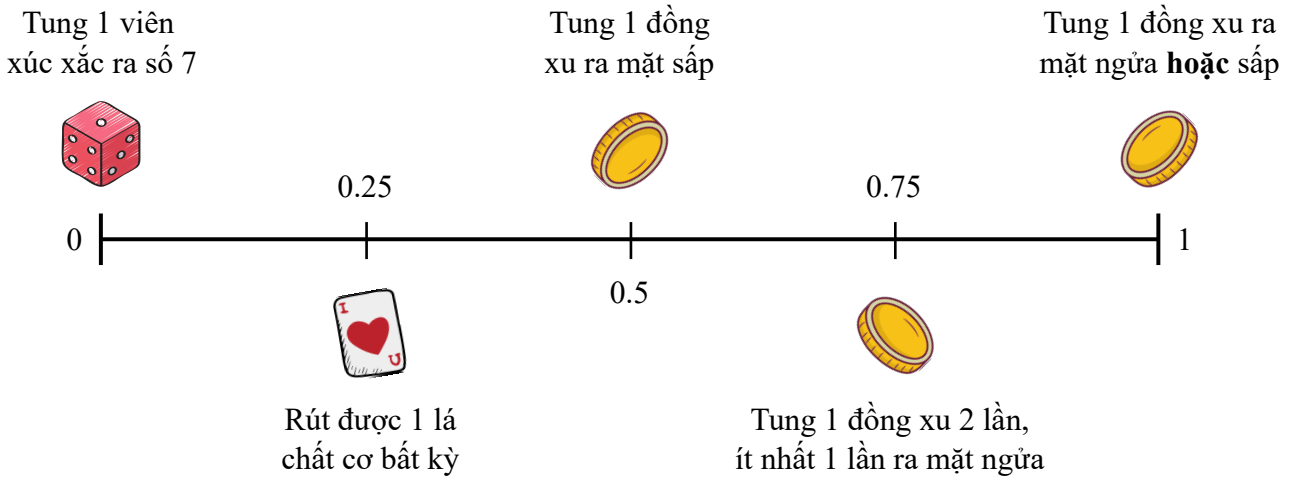
Đây chính là lý do chúng ta cần một loss function (tạm dịch: hàm mất mát), một thước đo cho phép so sánh các mô hình, và quan trọng hơn là cho phép mô hình tự cập nhật tham số trong quá trình học. Tài liệu này sẽ đi qua bốn trạm dừng chân, từ **Xác suất & Logarithm**, đến **Entropy**, rồi **Cross Entropy**, và cuối cùng là **hàm mất mát với Cross Entropy**.

Làm quen với Xác suất và Logarithm

Nhập môn xác suất cơ bản

Trước khi khám phá Cross Entropy, chúng ta cần hiểu hai khái niệm cơ bản nhất gồm xác suất và logarithm. Đừng quá lo lắng nếu chưa quen với toán học phức tạp, hai khái niệm này có thể hiểu một cách trực giác mà không cần quá nhiều ký hiệu.

Xác suất là một con số nằm trong khoảng từ 0 đến 1, biểu thị mức độ tin tưởng rằng một sự kiện sẽ xảy ra. Con số 0 có nghĩa là không thể xảy ra, con số 1 có nghĩa là chắc chắn xảy ra. Một tính chất quan trọng là tổng xác suất của tất cả các khả năng phải bằng 1.

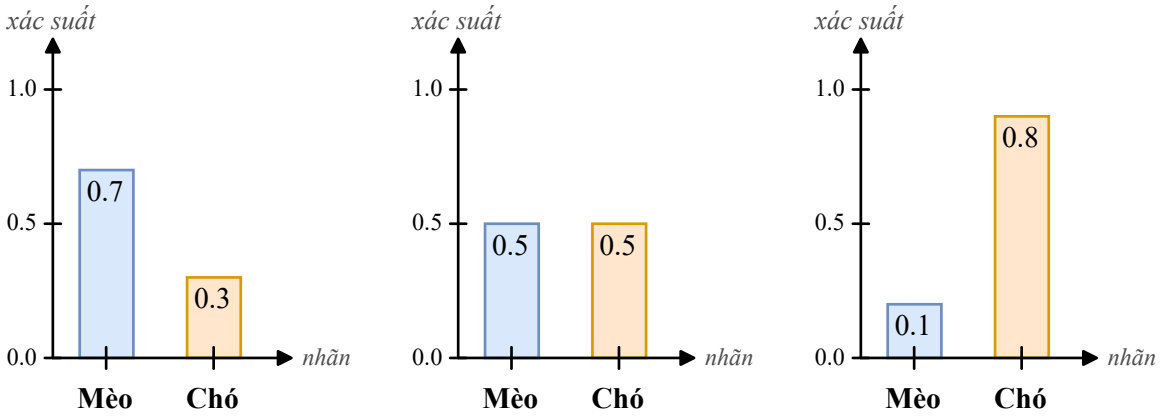


Hình 2: Ví dụ các mức xác suất từ không thể (0) đến chắc chắn (1).

Trong thực tế học máy, dữ liệu mà chúng ta gặp thường rơi vào hai dạng chính. Hãy thử suy nghĩ về các bài toán phân loại mà bạn có thể gặp. Có những bài toán chỉ cần trả lời có hoặc không, đúng hay sai. Ví dụ như phát hiện email spam hay không spam. Nhưng cũng có những bài toán phức tạp hơn, chúng ta cần chọn một trong nhiều khả năng, ví dụ như nhận dạng ảnh là mèo, chó, chim, hay cá.

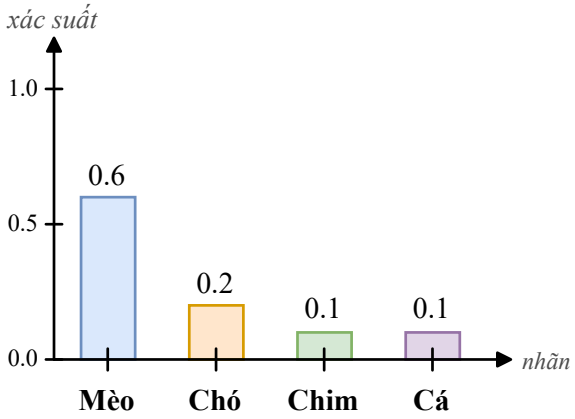
Sự khác biệt này trong cách đặt vấn đề dẫn đến hai loại phân phối xác suất tương ứng:

- Bernoulli distribution (phân phối Bernoulli): dành cho trường hợp nhị phân, tức là chỉ có hai kết quả có thể. Ví dụ như chỉ có hai nhãn là "mèo" hoặc "không phải mèo".



Hình 3: Ví dụ trực quan về các phân phối Bernoulli khác nhau cho hai nhãn "Mèo" và "Chó".

- Categorical distribution (phân phối Categorical): dành cho trường hợp đa nhãn, nơi có K kết quả khác nhau có thể xảy ra. Ví dụ, phân loại một tấm hình ảnh thuộc một trong bốn nhãn: "Mèo", "Chó", "Chim", hay "Cá".



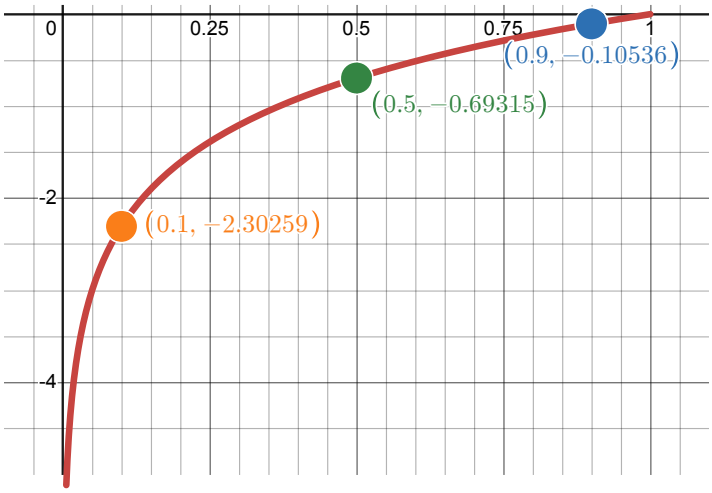
Hình 4: Minh họa một phân phối Categorical với bốn nhãn.

Tính chất của Logarithm - Vì sao lại dùng log?

Logarithm là phép toán ngược của phép lũy thừa. Nếu $b^x = a$, thì x chính là logarithm cơ số b của a, ký hiệu là $x = \log_b(a)$. Ví dụ, vì $2^3 = 8$ nên $\log_2(8) = 3$, hay vì $10^2 = 100$ nên $\log_{10}(100) = 2$.

Trong Cross Entropy, loại logarithm được sử dụng là *logarithm tự nhiên* với cơ số $e \approx 2.718$. Tuy nhiên, cần lưu ý về ký hiệu, logarithm tự nhiên thường được viết là $\ln(a)$ hoặc $\log_e(a)$, nhưng trong học máy, người ta viết gọn là $\log(a)$ và ngầm hiểu đây là logarithm tự nhiên. Các logarithm với cơ số khác như $\log_{10}(a)$ hay $\log_2(a)$ luôn được ghi rõ cơ số. Tương tự như vậy, tài liệu này cũng sử dụng logarithm tự nhiên.

Khi áp dụng logarithm lên một số trong khoảng $(0, 1)$, chúng ta nhận được một số âm. Khi số đó càng gần 0, giá trị log càng lớn về giá trị vô cùng. Bên dưới là một vài ví dụ cụ thể với log cơ số e trên các giá trị xác suất p.



Hình 5: Biểu đồ hàm $\log(p)$.

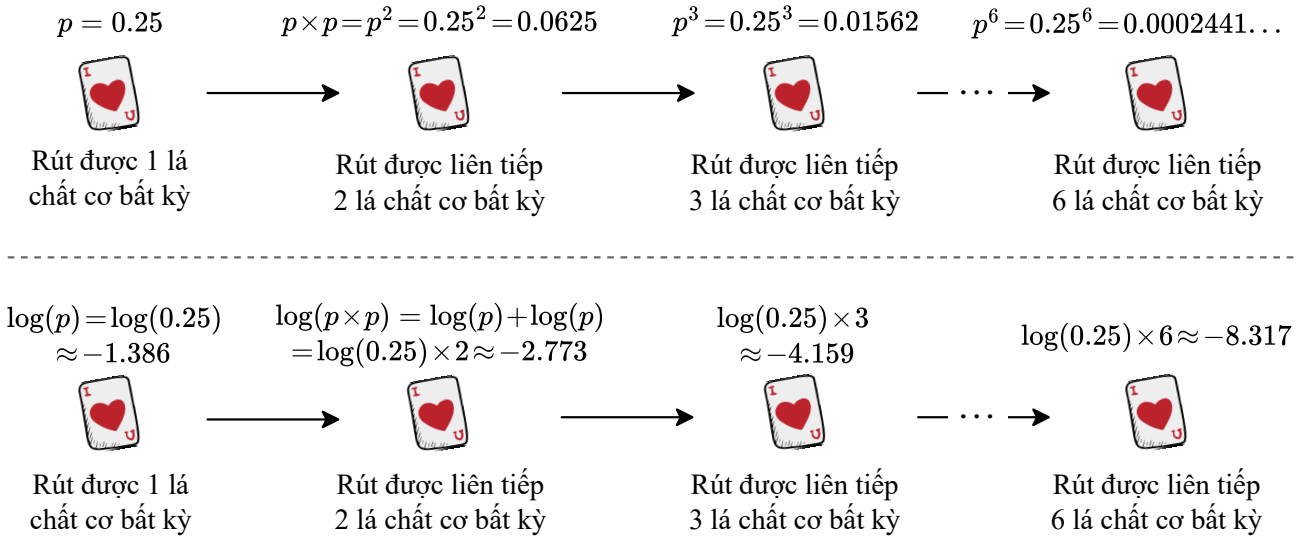
p	$\log(p)$	$-\log(p)$
0.9	-0.105	0.105
0.5	-0.693	0.693
0.1	-2.303	2.303

Bảng 1: Một vài giá trị cụ thể khi lấy log cho p.

Hai lý do chính khiến hàm log trở nên quan trọng:
Thứ nhất, log có tính chất biến phép nhân thành phép cộng:

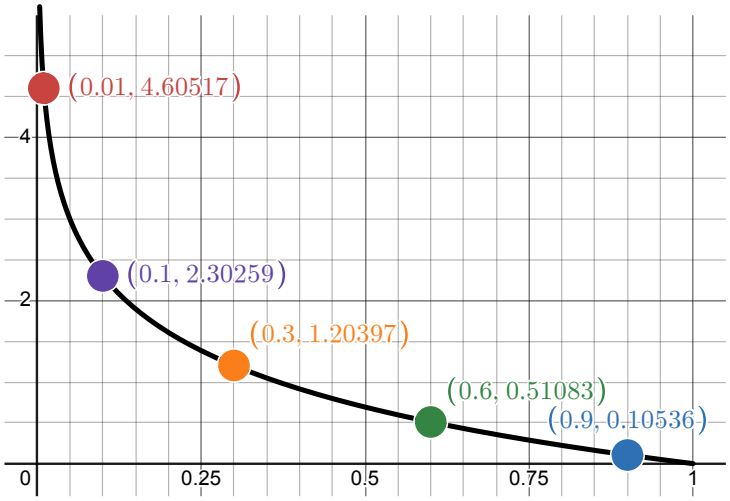
$$\log(a \times b) = \log(a) + \log(b). \tag{1}$$

Trong học máy, khi chúng ta cần nhân nhiều xác suất nhỏ với nhau, việc nhân trực tiếp dễ dẫn đến kết quả có giả trị quá nhỏ, đến mức mà máy tính không biểu diễn được. Để tránh lỗi, ta chuyển sang lấy log của các xác suất, khi đó, phép nhân trở thành phép cộng, giúp máy tính tính toán dễ hơn và chính xác hơn. Ví dụ cụ thể như hình bên dưới.



Hình 6: Log giúp tránh kết quả tính toán quá nhỏ khi nhân nhiều xác suất nhỏ.

Thứ hai, hàm $-\log$ tạo ra một "hình phạt" tự nhiên và hợp lý. Khi mô hình dự đoán sai với độ tự tin cao, nghĩa là xác suất gần 0 cho nhãn đúng, giá trị $-\log(p)$ sẽ tăng vọt lên rất lớn, tạo ra một lượng phạt rất nặng. Ngược lại, khi dự đoán đúng với độ tự tin cao, hình phạt gần như bằng 0.



Hình 7: Biểu đồ hàm âm logarithm tự nhiên.

Xác suất p	-log(p)
1.0	0.0
0.9	0.105
0.6	0.511
0.3	1.204
0.1	2.303
0.01	4.605

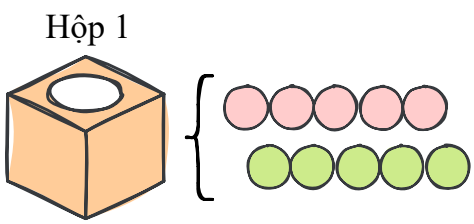
Bảng 2: Xác suất cho nhãn đúng càng thấp thì $-\log(p)$ càng lớn, tức là phạt càng nặng.

Hiểu Entropy là gì

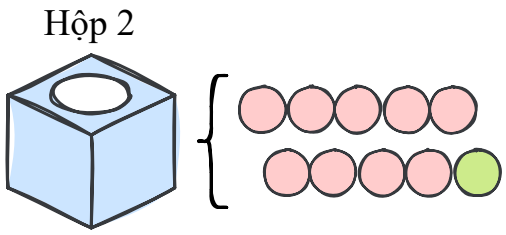
Trực giác về Entropy

Bây giờ, chúng ta đã sẵn sàng để đến với khái niệm đầu tiên là Entropy. Entropy đo lường mức độ bất định của một phân phối xác suất. Nói cách khác, nó cho biết "khó đoán" đến mức nào khi chúng ta rút ngẫu nhiên một kết quả từ phân phối đó.

Hãy bắt đầu với một quan sát đơn giản. Tưởng tượng có hai chiếc hộp, màu cam và màu xanh, mỗi hộp chứa các viên bi màu:



Hình 8: Hộp màu cam: chứa 5 viên bi đỏ và 5 viên bi xanh, mỗi màu có xác suất xuất hiện là 50%.



Hình 9: Hộp màu xanh: chứa 9 viên đỏ và 1 viên xanh, xác suất rút trúng bi đỏ là 90% và xanh chỉ 10%.

Nếu bịt mắt và rút ngẫu nhiên một viên bi từ một trong hai hộp, trường hợp nào sẽ khó đoán hơn?

Rõ ràng, hộp màu cam sẽ khó đoán hơn nhiều, vì xác suất cho mỗi màu là đều nhau, nên hoàn toàn không thể nghiêng về lựa chọn nào. Nhưng với hộp màu xanh, chỉ cần đoán là bi "đỏ" thì hầu hết là sẽ đúng mọi lần thử. Sự khác biệt này về mức độ bất định, chính là điều mà Entropy đo lường. Nó định lượng xem một phân phối xác suất "gây bối rối" đến mức nào khi phải đưa ra dự đoán.

Định nghĩa toán học

Vậy làm thế nào để biến trực giác về "độ khó đoán" thành một con số cụ thể? Hãy nghĩ như thế này, nếu một kết quả có xác suất cao, nó sẽ ít bất ngờ, nên không đóng góp nhiều vào "độ bất định". Ngược lại, các kết quả có xác suất thấp lại, nếu được xuất hiện thì sẽ rất bất ngờ, nên chúng tạo ra nhiều bất định hơn hay đóng góp nhiều hơn.

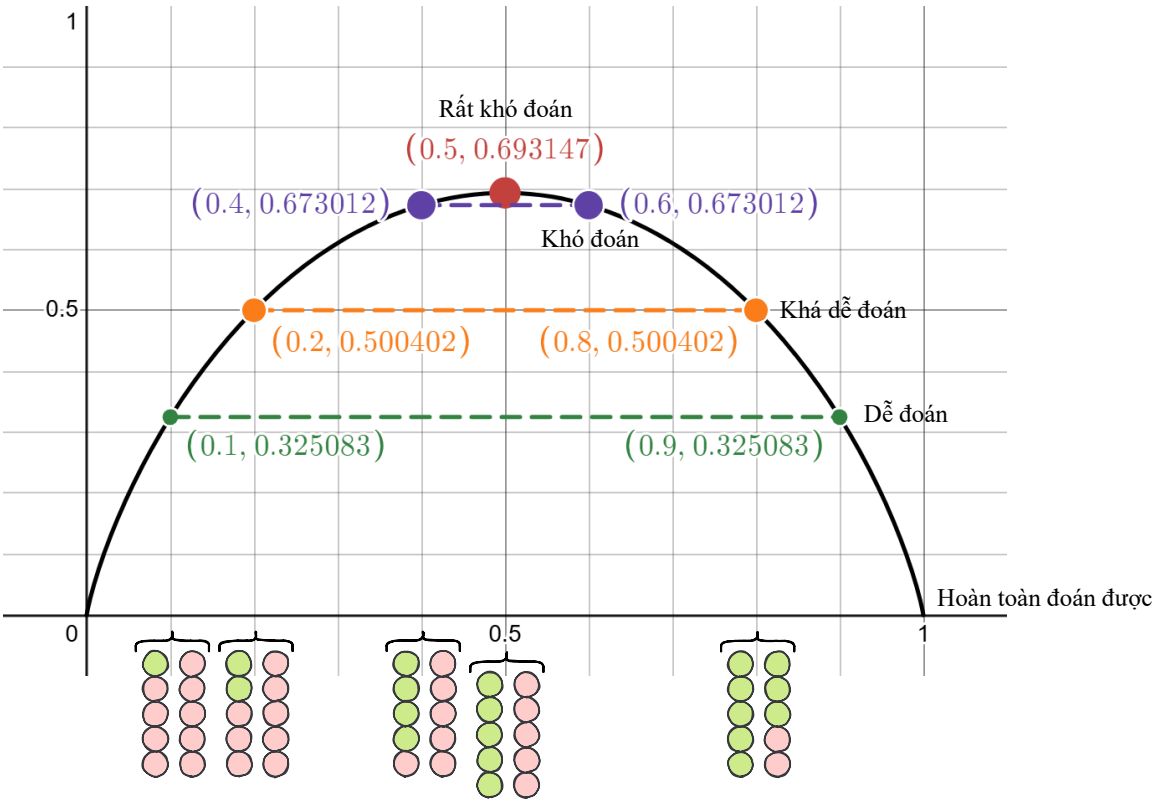
Nhớ lại rằng hàm $-\log(p)$ cung cấp một "thước đo độ bất ngờ", trong đó, xác suất p càng nhỏ thì giá trị $-\log(p)$ càng lớn. Nhưng chúng ta không thể chỉ cộng tất cả các giá trị $-\log(p)$ lại, vì những kết quả có xác suất thấp sẽ không ảnh hưởng nhiều đến độ bất định chung vì chúng hiếm khi xảy ra. Xem lại hình 7.

Giải pháp ở đây là đối với mỗi kết quả y, chúng ta lấy "độ bất ngờ" của nó là $-\log p(y)$ và nhân với "tần suất" của nó là $p(y)$. Điều này tạo ra một giá trị trung bình có trọng số theo độ bất ngờ.

Về mặt toán học, Entropy được ký hiệu là H, của một phân phối xác suất rời rạc P được định nghĩa dựa trên probability mass function (hàm khối xác suất) $p(y)$ của một biến ngẫu nhiên rời rạc y với tập giá trị có thể có là Y, như sau:

$$H(P) = -\sum_{y \in Y} p(y) \log p(y). \tag{2}$$

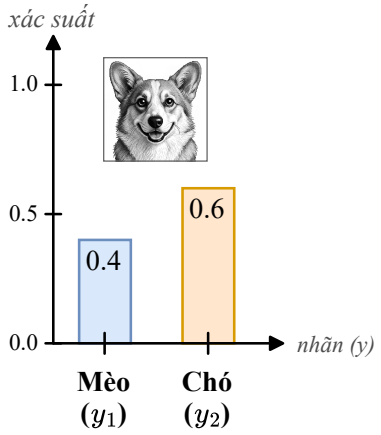
Ngoài ra, ta quy ước, khi $p(y) = 0$ thì $0 \log 0 = 0$.



Hình 10: Minh họa của biểu đồ Entropy với số lượng nhãn là 2.

Ví dụ đơn giản

Để dễ hiểu hơn cách tính Entropy, hãy xem ví dụ tính toán như bên dưới. Với một phân phối xác suất P như hình bên trái (Hình 11) thì $H(P)$ được tính như sau:



Hình 11: Minh họa về một phân phối xác suất P với hai nhãn y gồm mèo và chó.

Xác suất: $p(\text{Mèo}) = 0.4, \quad p(\text{Chó}) = 0.6$

Đóng góp Entropy từng nhãn:

$$\begin{aligned} H(\text{Mèo}) &= -p(\text{Mèo}) \log p(\text{Mèo}) \\ &= -0.4 \log 0.4 = -0.4(-0.9163) \approx 0.3665 \\ H(\text{Chó}) &= -p(\text{Chó}) \log p(\text{Chó}) \\ &= -0.6 \log 0.6 = -0.6(-0.5108) \approx 0.3065 \end{aligned}$$

Do đó, Entropy của phân phối là:

$$\begin{aligned} H(P) &= -\sum_y p(y) \log p(y) \\ &= -\Big(0.4 \log 0.4 + 0.6 \log 0.6\Big) \\ &= 0.3665 + 0.3065 = 0.6730. \end{aligned}$$

Các tính chất quan trọng

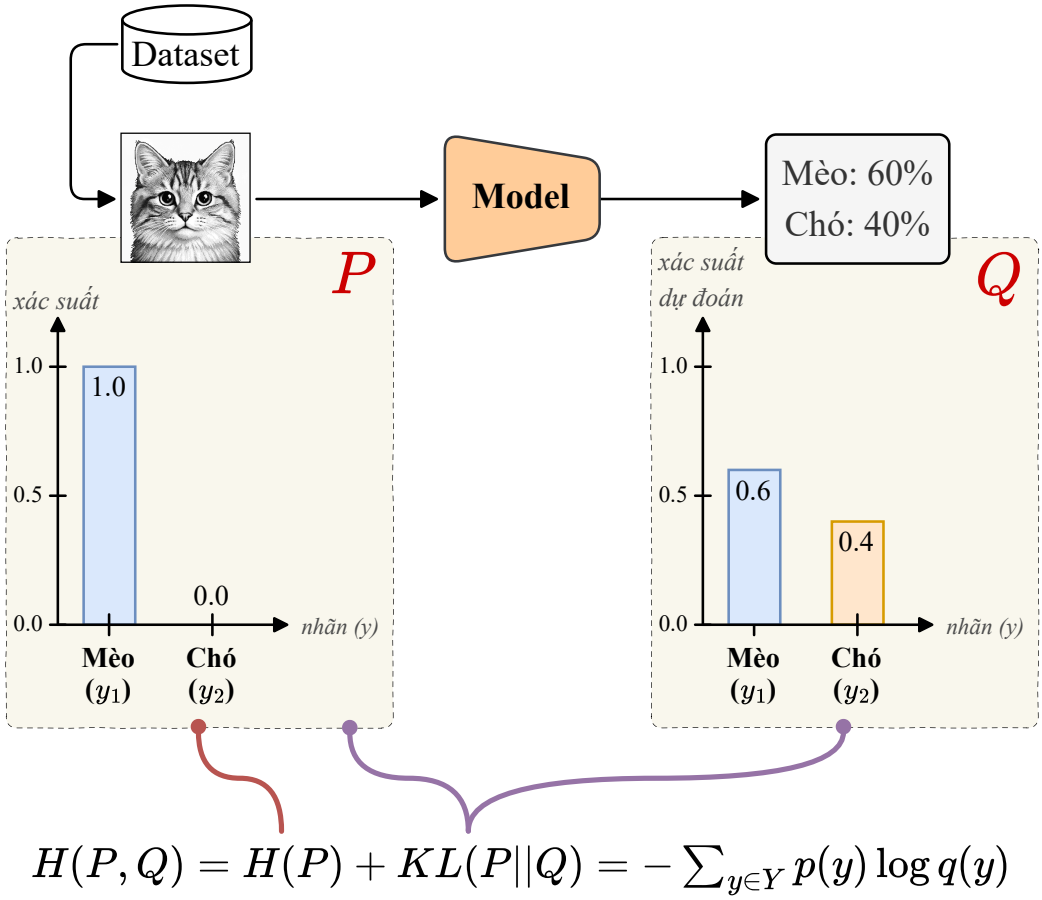
Entropy có một số tính chất quan trọng có thể quan sát được như trong hình 10:

1. Entropy luôn không âm: $H(P) \geq 0$.
2. Entropy đạt giá trị lớn nhất khi phân phối hoàn toàn đều. Với K nhãn, giá trị lớn nhất là $H_{max} = \log K$.
3. Nếu một kết quả chắc chắn xảy ra hoặc có xác suất bằng 1, thì Entropy bằng 0.

Từ Entropy tới Cross Entropy

Cross Entropy là gì?

Bây giờ chúng ta đến phần cốt lõi là Cross Entropy. Nếu Entropy đo "độ khó" vốn có của dữ liệu thật, thì Cross Entropy đo "độ khó" khi chúng ta cố gắng giải thích dữ liệu đó bằng một mô hình có thể sai, hoặc nói cách khác là đo mức độ không khớp giữa phân phối thật và phân phối mà mô hình tạo ra.



Hình 12: Minh họa giữa phân phối thật P và phân phối mà mô hình dự đoán Q.

Định nghĩa toán học của Cross Entropy giữa phân phối mục tiêu P với hàm khối xác suất $p(y)$ và phân phối dự đoán Q với hàm khối xác suất $q(y)$ được cho bởi:

$$H(P, Q) = -\sum_{y \in Y} p(y) \log q(y). \tag{3}$$

Khác với Entropy, nơi cả trọng số và giá trị log đều dựa trên cùng một phân phối $p(y)$, trong Cross Entropy, trọng số vẫn là $p(y)$, nhưng giá trị log được tính theo xác suất dự đoán $q(y)$. Điều này phản ánh mức độ phù hợp giữa dự đoán và phân phối thật.

Mối liên hệ với KL Divergence

Khi tính Cross Entropy như công thức số 3, ta đang dùng trọng số từ phân phối thật P nhưng tính độ bất ngờ theo phân phối dự đoán Q. Điều thú vị là có thể tách công thức này thành hai phần có ý nghĩa rõ ràng. Phần đầu tiên phản ánh độ bất định vốn có của dữ liệu, phần này chính là Entropy $H(P)$. Trong khi, phần thứ hai đo lường "mức phạt" khi chúng ta cố dùng phân phối sai Q thay vì phân phối đúng là P, và phần này có một cái tên riêng là *KL divergence*. Xem hình minh họa số 12.

Cụ thể, có một hệ thức quan trọng liên kết Cross Entropy với Entropy và KL divergence:

$$H(P,Q) = H(P) + KL(P||Q). \tag{4}$$

Trong đó:

- H(P) là Entropy của phân phối thật, giúp đo độ bất định vốn có trong dữ liệu.
- $KL(P||Q)$ là Kullback-Leibler divergence. Theo nghĩa thông tin, nó đo khoảng cách giữa phân phối thật P và phân phối do mô hình dự đoán Q:

$$KL(P||Q) = \sum_y p(y) \log \left(\frac{p(y)}{q(y)} \right). \tag{5}$$

Một cách phát biểu dễ nhớ theo trực giác là:

- Cross Entropy $H(P,Q)$ = độ bất định vốn có + mức phạt thêm do mô hình sai.
- Nếu mô hình hoàn hảo, nghĩa là phân phối Q giống hệt phân phối P, thì $KL(P||Q) = 0$, và Cross Entropy chỉ còn lại đúng bằng Entropy $H(P)$.

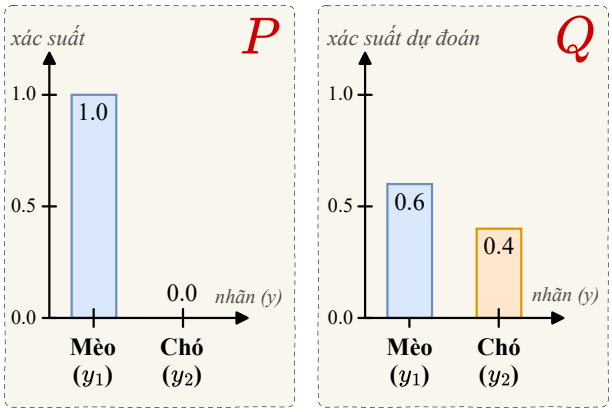
Dựa trên định nghĩa của Entropy và KL divergence, ta có thể xây dựng lại công thức của Cross Entropy như sau:

$$\begin{aligned}
H(P,Q) &= \underbrace{-\sum_{y \in Y} p(y) \log p(y)}_{\text{Entropy } H(P)} \quad + \quad \underbrace{\sum_{y \in Y} p(y) \log \left(\frac{p(y)}{q(y)} \right)}_{\text{KL divergence } KL(P||Q)} \\
&= -\sum_{y \in Y} p(y) \log p(y) \quad + \quad \sum_{y \in Y} p(y) \left[\log p(y) - \log q(y) \right] \\
&= -\sum_{y \in Y} p(y) \log p(y) \quad + \quad \sum_{y \in Y} \left[p(y) \log p(y) - p(y) \log q(y) \right] \\
&= -\sum_{y \in Y} p(y) \log p(y) \quad + \quad \sum_{y \in Y} p(y) \log p(y) \quad - \quad \sum_{y \in Y} p(y) \log q(y) \\
&= -\sum_{y \in Y} p(y) \log q(y) \qquad \text{(giống công thức số 3).}
\end{aligned}$$

Khi huấn luyện mô hình trong học máy, vì $H(P)$ là đặc trưng cố định của dữ liệu nên không phụ thuộc mô hình, do đó, khi huấn luyện, *việc tối thiểu hóa Cross Entropy tương đương với việc tối thiểu hóa KL divergence*, tức là làm cho phân phối dự đoán Q tiệm cận phân phối thật P.

Ví dụ tính toán

Lấy ví dụ như hình 12, giả sử trong tập dữ liệu, ảnh đầu vào là một con mèo, nên phân phối thật $P = [1.0, 0.0]$. Trong khi với cùng hình ảnh đó, mô hình dự đoán rằng có 60% xác suất là con "Mèo" và 40% là "Chó", tức là phân phối dự đoán $Q = [0.6, 0.4]$, được minh họa như hình vẽ bên dưới đây:



Hình 13: Minh họa cho hai phân phối xác suất P và Q.

Cross Entropy giữa P và Q được tính theo công thức:

$$H(P,Q) = -\sum_{y \in Y} p(y) \log q(y).$$

Vì $p(y_1) = 1.0$ và $p(y_1) = 0.0$:

$$\begin{aligned} H(P,Q) &= -\Big[p(y_1)\log q(y_1) + p(y_2)\log q(y_2)\Big] \\ &= -(1.0 \log 0.6 + 0.0 \log 0.4) \\ &= -\log 0.6 \approx 0.511. \end{aligned}$$

Kết luận: Cross Entropy trong trường hợp này bằng khoảng 0.511, cho thấy mô hình đã gán xác suất tương đối chính xác nhưng chưa tuyệt đối cho nhãn đúng là "Mèo". Nếu mô hình càng tự tin hơn, nghĩa là xác suất gần 1.0 hơn cho "Mèo" thì giá trị Cross Entropy sẽ nhỏ hơn nữa.

Cross Entropy trong vai trò hàm mất mát

Sau khi hiểu, chúng ta cần biết cách áp dụng Cross Entropy làm loss function (tạm dịch: hàm mất mát) trong học máy. Nhắc lại công thức tổng quát từ phần :

$$H(P,Q) = -\sum_{y \in Y} p(y) \log q(y). \tag{6}$$

Công thức này trông có vẻ trừu tượng nhưng thực chất rất đơn giản. Với mỗi kết quả có thể xảy ra, ta lấy xác suất thật $p(y)$ nhân với log của xác suất mà mô hình dự đoán $q(y)$, rồi cộng tất cả lại. Dấu trừ ở đầu giúp biến kết quả thành số dương.

Trong học máy, tùy vào bài toán có bao nhiêu nhãn cần phân loại mà công thức này sẽ có hình dạng cụ thể khác nhau. Sau đây, chúng ta sẽ cùng khám phá hai trường hợp phổ biến nhất.

Trường hợp nhị phân: Binary Cross Entropy

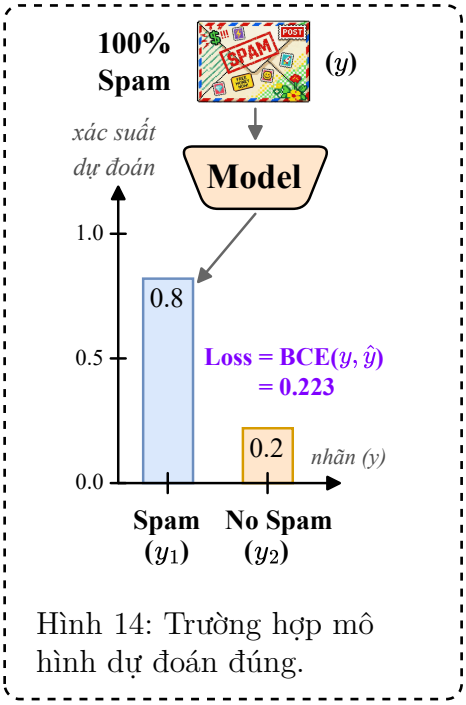
Tưởng tượng bạn đang xây dựng một mô hình để phân loại email là spam hoặc không spam. Đây là bài toán nhị phân vì chỉ có hai khả năng. Trong trường hợp này, chúng ta thường dùng số 0 để biểu diễn một nhãn, lấy ví dụ là "không spam" và số 1 cho nhãn "spam". Mô hình sẽ cho ra một con số từ 0 đến 1, ví dụ 0.8 có nghĩa là mô hình tin 80% rằng email này là "spam".

Xây dựng công thức từng bước
Hãy bắt đầu với một ví dụ cụ thể. Giả sử chúng ta có một email thực sự là spam, nghĩa là nhãn thật $y = 1$. Mô hình dự đoán xác suất là spam là $\hat{y} = 0.8$.

Bước 1: Hiểu phân phối thật
Khi nhãn thật là spam ($y = 1$), điều này có nghĩa là phân phối xác suất thật đặt toàn bộ 100% vào nhãn "spam" và 0% vào nhãn "không spam". Nói cách khác, $p(\text{spam}) = 1$ và $p(\text{không spam}) = 0$.

Bước 2: Hiểu phân phối dự đoán
Mô hình dự đoán $\hat{y} = 0.8$ có nghĩa là $q(\text{spam}) = 0.8$. Vì tổng xác suất phải bằng 1.0, nên $q(\text{không spam}) = 1.0 - 0.8 = 0.2$.

Bước 3: Áp dụng công thức Cross Entropy
Theo công thức tổng quát, chúng ta cộng tất cả các trường hợp có thể:



Hình 14: Trường hợp mô hình dự đoán đúng.

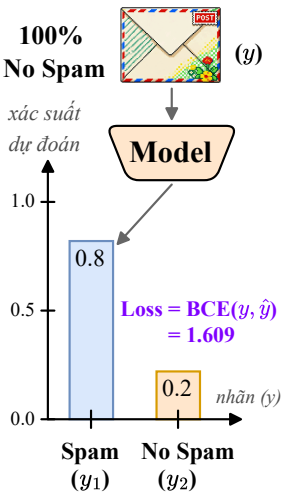
$$\begin{aligned} H(P,Q) &= -[p(\text{spam}) \log q(\text{spam}) + p(\text{không spam}) \log q(\text{không spam})] \\ &= -[1 \log(0.8) + 0 \log(0.2)] \\ &= -\log(0.8) \approx 0.223. \end{aligned}$$

Chú ý rằng số hạng thứ hai bị triệt tiêu vì $p(\text{không spam}) = 0$. Điều này hợp lý vì nhãn thật là "spam", nên chúng ta chỉ quan tâm đến việc mô hình gán bao nhiêu xác suất cho nhãn "spam".

Bước 4: Trường hợp ngược lại
Bây giờ giả sử email thực ra không phải "spam", nghĩa là $y = 0$, nhưng mô hình vẫn dự đoán $\hat{y} = 0.8$ (mô hình đang sai). Lúc này, phân phối thật là $p(\text{không spam}) = 1$ và $p(\text{spam}) = 0$. Cross Entropy trở thành:

$$\begin{aligned} H(P,Q) &= -[0 \log(0.8) + 1 \log(0.2)] \\ &= -\log(0.2) \approx 1.609. \end{aligned}$$

Lần này, số hạng đầu bị triệt tiêu và chúng ta chỉ còn $-\log(1 - \hat{y})$. Loss lớn hơn nhiều so với trường hợp trước, điều này hợp lý vì mô hình đang sai nhưng rất tự tin (80%).



Hình 15: Trường hợp mô hình dự đoán sai.

Bước 5: Gộp thành một công thức thống nhất
Để không phải viết hai công thức riêng cho hai trường hợp, người ta nghĩ ra một cách thông minh để gộp chúng lại. Nếu dùng y để biểu thị nhãn thật (0 hoặc 1), công thức sau sẽ tự động chọn đúng số hạng:

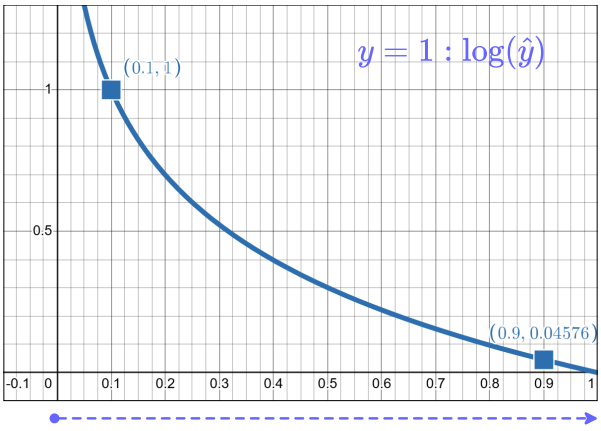
$$\text{BCE}(y, \hat{y}) = -\Big[y \log(\hat{y}) + (1-y)\log(1-\hat{y})\Big]. \tag{7}$$

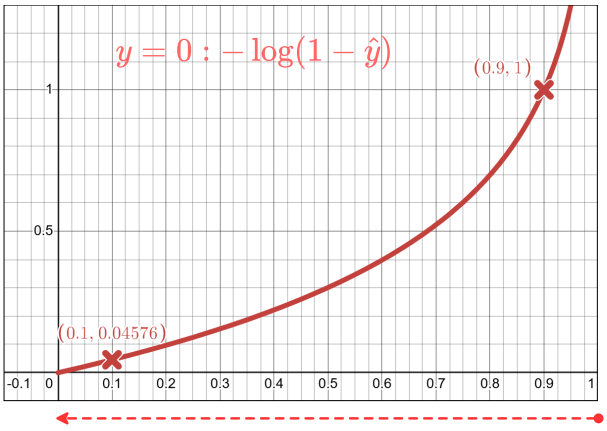
Hãy kiểm tra xem công thức này có hoạt động không:

- Khi $y = 1$ (nhãn thật là nhãn 1): số hạng $(1-y) = 0$, vậy chỉ còn $-\log(\hat{y})$, giống bước 3.
- Khi $y = 0$ (nhãn thật là nhãn 0): số hạng $y = 0$, vậy chỉ còn $-\log(1-\hat{y})$, giống bước 4.

Đây chính là công thức cho hàm mất mát Binary Cross Entropy (BCE). Với toàn bộ tập dữ liệu gồm N email, chúng ta tính trung bình loss của tất cả:

$$\text{BCE Loss} = \frac{1}{N}\sum_{i=1}^{N} \text{BCE}(y_i, \hat{y}_i). \tag{8}$$





Hình 16: Biểu đồ Binary Cross Entropy cho thấy loss tăng rất nhanh hay phạt rất nặng khi mô hình dự đoán sai với độ tự tin cao.

Trường hợp phân loại nhiều nhãn: Categorical Cross Entropy

Bây giờ hãy tưởng tượng bài toán phức tạp hơn, ta cần phân loại động vật trong hình là loài nào trong ba loài: mèo, chó, hoặc chim. Đây là bài toán đa nhãn vì có nhiều hơn hai khả năng. Cách biểu diễn nhãn và hàm mất mát cũng thay đổi theo.

Biểu diễn các nhãn với One-hot Encoding

Trong bài toán đa nhãn, mô hình không chỉ cho ra một con số duy nhất nữa, mà cho ra nhiều giá trị xác suất của mỗi nhãn. Ví dụ mô hình có thể dự đoán $\hat{\mathbf{y}} = [0.7, 0.2, 0.1]$, có nghĩa là 70% tin là mèo, 20% tin là chó, 10% tin là chim.

Để tính Cross Entropy một cách nhất quán, chúng ta cần phân phối thật cũng ở dạng tương tự. Để làm được như vậy, chúng ta biểu diễn phân phối này dưới dạng một vector, trong đó chỉ có một vị trí bằng 1 cho nhãn đúng, và các vị trí khác đều bằng 0. Cách biểu diễn này gọi là

One-hot Encoding. Điều này cho phép chúng ta áp dụng công thức Cross Entropy một cách trực tiếp giữa hai phân phối xác suất.

Ví dụ với ba nhãn mèo, chó, chim:

- Nếu ảnh là mèo, nhãn sẽ là $\mathbf{y} = [1, 0, 0]$ (chỉ vị trí đầu tiên bằng 1),
- Nếu ảnh là chó, nhãn sẽ là $\mathbf{y} = [0, 1, 0]$ (chỉ vị trí thứ hai bằng 1),
- Nếu ảnh là chim, nhãn sẽ là $\mathbf{y} = [0, 0, 1]$ (chỉ vị trí thứ ba bằng 1).

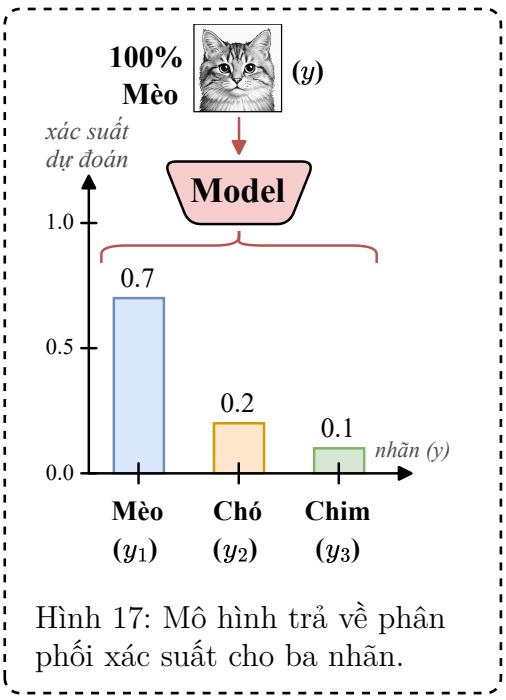
Xây dựng công thức từng bước

Hãy lấy ví dụ cụ thể như sau, giả sử ảnh thực sự là mèo, nên nhãn thật là $\mathbf{y} = [1, 0, 0]$ và mô hình cho dự đoán $\hat{\mathbf{y}} = [0.7, 0.2, 0.1]$.

Bước 1: Áp dụng công thức tổng quát
Với ba nhãn, công thức Cross Entropy tổng quát là:

$$H(P, Q) = -\sum_{k=1}^{3} p(k) \log q(k).$$

Điều này có nghĩa là chúng ta cộng ba số hạng lại với nhau, mỗi số hạng ứng với một nhãn.



Hình 17: Mô hình trả về phân phối xác suất cho ba nhãn.

Bước 2: Thay các giá trị cụ thể
Nhãn thật $\mathbf{y} = [1, 0, 0]$ cho chúng ta biết:

$$p(\text{Mèo}) = 1, \quad p(\text{Chó}) = 0, \quad p(\text{Chim}) = 0.$$

Dự đoán $\hat{\mathbf{y}} = [0.7, 0.2, 0.1]$ cho chúng ta:

$$q(\text{Mèo}) = 0.7, \quad q(\text{Chó}) = 0.2, \quad q(\text{Chim}) = 0.1.$$

Thay vào công thức:

$$\begin{aligned} H(P, Q) &= -[p(\text{Mèo}) \cdot \log q(\text{Mèo}) + p(\text{Chó}) \cdot \log q(\text{Chó}) + p(\text{Chim}) \cdot \log q(\text{Chim})] \\ &= -[1 \cdot \log(0.7) + 0 \cdot \log(0.2) + 0 \cdot \log(0.1)] \\ &= -\log(0.7) \approx 0.357. \end{aligned}$$

Bước 3: Nhận xét
Hai số hạng cuối bị triệt tiêu vì nhãn của chúng bằng 0. Điều này là do ảnh thực sự là mèo, nên chúng ta chỉ quan tâm đến xác suất mà mô hình gán cho nhãn mèo, trong khi, các nhãn khác không ảnh hưởng đến loss. Vậy công thức tổng quát cho K nhãn là:

$$\text{CCE}(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_{k=1}^{K} y_k \log(\hat{y}_k). \tag{9}$$

Trong đó $\mathbf{y}$ là vector one-hot của nhãn thật và $\hat{\mathbf{y}}$ là vector xác suất dự đoán từ mô hình. Với toàn bộ tập dữ liệu, ta có công thức sau:

$$\text{CCE Loss} = \frac{1}{N}\sum_{i=1}^{N} \text{CCE}(\mathbf{y}_i, \hat{\mathbf{y}}_i). \tag{10}$$

Tổng kết

Qua hành trình này, chúng ta đã làm rõ câu hỏi "Làm sao để đo lường độ tự tin của mô hình?" và khám phá cách Cross Entropy trở thành công cụ không thể thiếu trong học máy hiện đại. Từ những khái niệm nền tảng về xác suất và logarithm, chúng ta đã xây dựng dần lên Entropy, là thước đo độ bất định, rồi Cross Entropy, là thước đo sự khác biệt giữa dự đoán và thực tế.

Việc hiểu rõ bản chất của Cross Entropy không chỉ giúp chúng ta sử dụng đúng hàm mất mát, mà còn mở ra khả năng điều chỉnh và tối ưu mô hình trong các tình huống thực tế phức tạp hơn. Toàn bộ kiến thức của bài viết có thể được tóm gọn trong các công thức quan trọng sau:

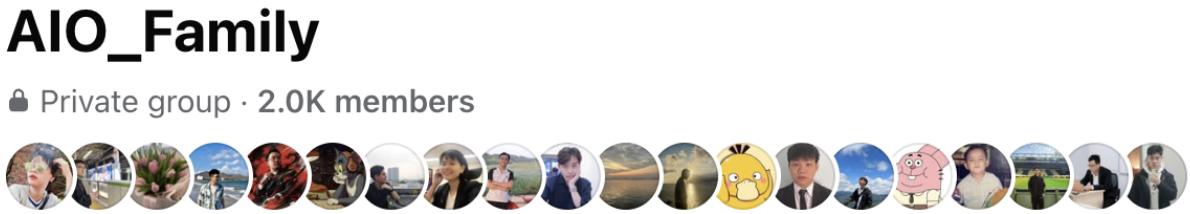
Kiến thức trọng tâm

Nội dung	**Ý nghĩa chính**
Logarithm	Công cụ toán học biến phép nhân thành phép cộng, giúp tránh tính toán với số quá nhỏ. Hàm $-\log(p)$ tạo ra "hình phạt" tự nhiên rằng dự đoán sai với độ tự tin càng cao thì bị phạt càng nặng.
Entropy	$H(P) = -\sum_y p(y)\log p(y)$ đo lường độ bất định vốn có của phân phối xác suất. Giá trị cao nghĩa là khó đoán, giá trị thấp nghĩa là dễ dự đoán.
Cross Entropy	$H(P,Q) = -\sum_y p(y)\log q(y)$ đo mức độ không khớp giữa phân phối thật P và phân phối dự đoán Q. Giá trị càng nhỏ, mô hình càng chính xác.
KL Divergence	$H(P,Q) = H(P) + KL(P\|\|Q)$ cho thấy Cross Entropy bao gồm độ bất định vốn có cộng với mức phạt do dự đoán sai. Tối thiểu hóa Cross Entropy tương đương với tối thiểu hóa KL divergence.
Binary Cross Entropy	$\text{BCE}(y,\hat{y}) = -[y\log(\hat{y}) + (1-y)\log(1-\hat{y})]$ dành cho bài toán nhị phân (hai nhãn), tự động chọn số hạng phù hợp dựa trên nhãn thật.
Categorical Cross Entropy	$\text{CCE}(\mathbf{y},\hat{\mathbf{y}}) = -\sum_{k=1}^{K} y_k \log(\hat{y}_k)$ dành cho bài toán đa nhãn, sử dụng one-hot encoding để biểu diễn nhãn.

Cross Entropy là cầu nối giữa lý thuyết thông tin và học máy, giúp mô hình học cách tự tin đúng chỗ.

Phụ lục

Q&A: Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 tiếng.



Hình 18: Hình ảnh group facebook AIO Q&A.